Introduction---Motivation

尽管现有的 Web 攻击检测方法表现出优异的性能，但它们遵循 “一个数据集，一个模型” 的学习范式，需要在特定数据集上进行训练，并依赖充足的训练数据为每个数据集构建检测模型。

然而，新型网络攻击模式正迅速涌现，而训练高质量的检测模型通常需要大量的标注数据。在实际应用中，获取足够的标注数据极具挑战性，尤其是在企业环境中，不同网络环境和业务场景下的攻击样本分布差异显著。为每个新场景重新训练模型不仅计算成本高昂、耗时费力，尤其是当新场景的标注数据稀缺时，这一问题更为突出。

鉴于上述局限性，一个自然的问题应运而生：我们能否训练一个 “通用” 的 Web 攻击检测模型，使其能够泛化到不同场景下的各种 Web 攻击检测数据集？

Introduction---Contribution

- 1. 通用Web攻击检测模型的提出：我们首次提出并实现了一个通用的Web攻击检测模型，该模型能够在不依赖特定数据集训练的情况下，泛化到不同场景下的各种Web攻击检测数据集。为解决标注数据稀缺和新攻击模式快速涌现的问题提供了全新思路。
- 2. 创新的特征处理和对齐技术：我们设计了高效的特征处理流程。采用ETBERT将原始流量数据转化为高维通用特征向量；通过PCA降维降低计算成本并去除噪声；利用平滑度排序技术，基于特征方差对齐不同数据集的语义空间。这一流程确保了模型在多样化场景下的准确性和鲁棒性，为跨数据集特征一致性提供有效支持。
- 3.实验结果：在四个数据集上，我们的模型平均 F1 分数达到 xx

Related work

在除web attack detection的领域，存在一些通用模型。

例如图异常识别的GAD、CV异常识别的InCTRL、WinCLIP、GeneralAD、表格数据（是分类，而非异常检测）中的PORTAL、Towards Cross-Table Masked Pretraining for Web Data Mining。

在web attack detection的领域，有From zero-shot machine learning to zero-day attack detection等等。但是这些是使用比较naive的方法，在一些数据集上预训练，另外一些数据集上测试。还未存在“通用模型”。

方法、模型（GAD的部分）

1.PCA降维：用于统一特征维度
2.平滑度排序：用于统一语义

Feature Projection. At the first step of ARC, we employ a feature projection block to unify the feature dimensionality of multiple graph datasets [20]. Specifically, given a feature matrix $\mathbf{X}^{(i)} \in \mathbb{R}^{n^{(i)} \times d^{(i)}}$ of $\mathcal{D}^{(i)} \in \mathcal{T}_{train} \cup \mathcal{T}_{test}$, the feature projection is defined by a linear mapping:

$$\tilde{\mathbf{X}}^{(i)} \in \mathbb{R}^{n^{(i)} \times d_u} = \mathrm{Proj}\left(\mathbf{X}^{(i)}\right) = \mathbf{X}^{(i)}\mathbf{W}^{(i)}, \tag{1}$$

where $\tilde{\mathbf{X}}^{(i)}$ is the projected feature matrix for $\mathcal{D}^{(i)}$, d_u is a predefined projected dimension shared across all datasets, and $\mathbf{W}^{(i)} \in \mathbb{R}^{d^{(i)} \times d_u}$ is a dataset-specific linear projection weight matrix. To maintain generality, $\mathbf{W}^{(i)}$ can be defined using commonly used dimensionality reduction approaches such as singular value decomposition [53] (SVD) and principal component analysis [54] (PCA).

Smoothness-Based Feature Sorting. Although feature projection can align dimensionality, the semantic meaning of each projected feature across different datasets remains distinct. Considering the difficulty of semantic-level matching without prior knowledge and specific fine-tuning [19, 20], in this paper, we explore an alternative pathway: aligning features based on their contribution to anomaly detection tasks. Through analytical and empirical studies, we pinpoint that *the smoothness of each feature is strongly correlated with its contribution to GAD*. Building on this insight, in ARC, we propose to sort the features according to their contribution as our alignment strategy.

方法、模型（我的）

1.ETBERT的意义：用于将原始的pcap数据**转化为数值向量**，可用于后续处理；并且ETBERT**具有通用性**，能够提取出流量的通用特征（这是和GAD不同的部分）
2.PCA的意义：其一，密文数据，尤其是通过模型（如 ETBERT ）转化为高维特征向量（例如 768 维）时，计算成本较高。PCA 将这些高维特征降到更低的维度（例如 256 维），**显著减少后续处理的计算负担**。这对于需要实时或大规模分析的场景（如网络流量监控）尤为重要。其二，去噪和冗余去除，ETBERT 统一了特征的维度和分布，但数据中可能仍存在噪声或冗余。PCA 聚焦于方差较大的成分，可以有效**过滤掉不重要的特征或噪声**，提升数据的质量和后续模型的鲁棒性。
3.排序的意义：由于PCA提取出来的向量语义信息并不相同，所以需要排序把不同数据集、不同形式的特征的**语义对齐到一个共同的、与异常检测任务相关的特征空间**。这种对齐不需要依赖原本的特征，而是基于特征对异常检测的贡献程度（由方差衡量）

具体实现细节

- 1.流量提取特征部分
  - payload截取为128位，输入ETBERT，得到768维向量（与ETBERT预训练保持一致）
  - 明文URL截取为512位，输入BERT，得到768维向量
- 2.PCA降维部分：不同数据集分别进行降维，分别拟合PCA数据(遵照GAD的方法)
- 3.排序部分：借鉴GAD的方法，是按照方差排序
- 4.分类层：尝试了多种方法，最终采取效果最好的MLP

实验设置（GAD的实验设置）

- Baselines
  - 三个SOTA：仅预训练
  - 四个无监督：仅预训练&预训练 + 微调
  - 两个有监督：仅预训练
  - 为了验证GAD方法相比其他的方法有优越性
- Metric
  - AUROC and AUPRC
- 上下文节点数量的有效性
  - 为了验证节点数量对方法效果的影响
- 消融研究
  - 使用随机投影替换基于平滑性的特征对齐；
  - 使用 GCN 替换自邻残差图编码器；
  - 使用基于二分类的预测器和损失函数替换跨注意力上下文异常评分
  - 为了验证各个模块的不可缺失性
- 效率分析
  - 为了验证效率方面显著优于其他方法
- 细节
  - 其他baselines：使用可学习的投影或随机投影作为原始特征与模型输入层之间的适配器
  - 超参数：目标是训练通用 GAD ，不进行数据集特定的超参数搜索

实验设置（我的实验）

- Baselines
  - **2个Web attack detection的SOTA**：仅预训练&在目标数据集上训练&测试（分别是Zerowall、From zero-shot machine learning to zero-day attack detection）
  - **1个其他领域的通用模型方法迁移到web attack检测中来**：仅预训练（是表格数据的PORTAL）
  - 为了验证我的方法相比其他的方法有优越性
- 消融研究
  - **去掉排序**，随机投影之后，直接输入分类层
  - **对于加密流量：去掉ETBERT**，直接将payload输入分类层
  - 为了验证各个模块的不可缺失性
- Metric
  - AUROC and AUPRC and F1，实验表格只写了F1分数
- 细节
  - 其他baselines：使用可学习的投影作为原始特征与模型输入层之间的适配器
  - 超参数：目标是训练通用 GAD ，不进行数据集特定的超参数搜索

实验设置---数据集

- 训练：
- CIC-IDS2017
- UNSW-NB15
- 测试
- CIC-DDOS2019
- CTU-13
- 测试的攻击手段，是已经包含在训练集的攻击手段内的

实验结果（F1）

数据集	CTU	DDOS
Full model	0.6658	0.8436
去掉排序	0.5874	0.8198
去掉ETBERT	0.6259	0.7805

数据集	CTU	DDOS
SOTA1:zerowall	0.5862	0.6923
SOTA2	0.5986	0.7356
其他领域的通用方法1	0.6379	0.7812